

Detecção do Mosquito *Aedes Aegypti* através do Processamento e Classificação de Áudio

Aluno: Eurico Delmondes do Nascimento Júnior (MATRÍCULA:20199025779)

E-mail: euricojunior15@hotmail.com; Período da Graduação: VI

Orientador: Deborah Maria Vieira Magalhães

13 de julho de 2022

Resumo

Contexto: Desde o século 16, o *Aedes Aegypti* vem se espalhando por regiões tropicais e subtropicais do nosso planeta. Sua proliferação se dá por diversos fatores, como a urbanização descontrolada, aquecimento global e o aumento da resistência aos inseticidas, se tornando um grande desafio para o combate contra o principal vetor da transmissão da dengue e outras doenças como, febre amarela, Chikungunya e Zika.

Problema: São utilizados métodos de identificação manual dos focos, onde o agente de saúde fica responsável por uma zona de 800 a 1000 imóveis, nos municípios infestados por *Aedes*. Em ciclos bimensais o agente se encarrega de ir à procura por locais com água parada e instalação de armadilhas para mosquitos, tendo como objetivo evitar a formação de criadouros, tão quanto a sua proliferação. Dito isso, é notável a utilização de recursos financeiros, humanos e tempo para detecção de focos do mosquito.

Proposta: A proposta desse trabalho é a criação de um descritor compacto utilizando técnicas de processamento e extração de características a partir do áudio produzido pela batidas das asas dos mosquitos. De modo que esse conjunto de características possam servir de entrada para o classificador, tornando-o capaz de identificar a presença do *Aedes Aegypti*. Assim, abrindo margem para ser embarcado de forma fácil em um dispositivo móvel sem sobrecarregar seu nível de processamento e bateria.

Palavras-chaves: *Aedes Aegypti*, classificação de áudio, aprendizado de máquina.

1 Introdução

Desde o século 16, o *Aedes Aegypti* vem se espalhando por regiões tropicais e subtropicais do nosso planeta. Sendo que em 2019, diversos países endêmicos enfrentaram surtos massivos de dengue, ocasionando em grandes impactos economicos e humanos. Esta doença têm o mosquito *Aedes Aegypti* como seu principal vetor de transmissão. O qual também é transmissor do vírus da febre amarela, Chikungunya e Zika. Fora o aquecimento global, existe outro aspecto desafiador, os mosquitos estarem desenvolvendo uma maior resistência aos inseticidas. Sendo que, programas de controle de vetores, dependem do uso

de inseticidas, não dispensando também, vigilância e monitoramento (FANIOUDAKIS; GEISMAR; POTAMITIS, 2018). Dito isso, é de extrema importância, compreender o número e a localização de ponteciais focos de proliferação para ajudar na redução da transmissão (KISKIN et al., 2020).

Diferentes estratégias são adotadas para ajudar no combate à proliferação do *Aedes Aegypti* como, por exemplo, identificação de locais com água parada, propícios para a reprodução do mosquito, instalação de armadilhas para mosquitos e utilização de mosquitos que são modificados geneticamente para não se reproduzirem (FERNANDES; CORDEIRO; RECAMONDE-MENDOZA, 2021). É também importante ressaltar que a conscientização da comunidade local é de extrema importância para combater a incidência do mosquito em uma região.

Dito isso, soluções para a detecção automática de mosquitos que se baseiam em processamento de áudio e técnicas de aprendizado de máquina para detecção automática de mosquitos através dos tons produzidos durante seu vôo têm sido investigadas na literatura. Por exemplo, (FERNANDES; CORDEIRO; RECAMONDE-MENDOZA, 2021) os quais utilizaram diversos áudios das batidas de asas do *Aedes aegypti* com o intuito de treinar uma rede neural convolucional (CNN) que fosse capaz de detectar a presença do *Aedes aegypti* e obtiveram êxito, tendo uma acurácia de 97,65% ($\pm 0,55$). Similarmente (FANIOUDAKIS; GEISMAR; POTAMITIS, 2018) uma rede, DenseNet121 que foi treinada com espectogramas extraídos das gravações do batimento de asas de 6 espécies de mosquitos, dentre elas o *Aedes aegypti*, e obtiveram uma acurácia de classificação de 96%.

Porém, apesar dessas soluções que se baseiam em aprendizado profundo demonstrarem resultados animadores e promissores em relação a classificação de mosquitos, diversos desafios surgem. Alguns deles são: a existência de um ruído de fundo nos áudios captados, algumas espécies de mosquitos diferentes possuem distribuições de frequência que são sobrepostas, acarretando em dificuldades na hora de diferenciá-las, a falta de informações como a data e a hora (JOSHI; MILLER, 2021). Fora que, tais soluções necessitam de uma enorme quantidade de dados e alto custo computacional, tornando a sua implementação em dispositivos, como o smartphone, desafiadora.

Dito isso, a proposta desse trabalho é investigar: com quais características extraídas do áudio possibilitam a criação de um descritor compacto, que possa ser embarcado de forma fácil em um dispositivo móvel, com o intuito de se tornar capaz de identificar a presença do *Aedes Aegypti* sem sobrecarregar seu nível de processamento e bateria? Essa resposta contribuirá para a detecção de forma automática e baixo custo de focos do *Aedes Aegypti*, e que auxiliará políticas públicas no combate à proliferação do mosquito.

1.1 Objetivos Gerais e Específicos

Objetivo Geral: Esta proposta tem como seu objetivo geral o desenvolvimento de uma metodologia para extração de características e classificação de dados acústicos que possam contribuir na detecção do mosquito *Aedes aegypti*.

Os objetivos específicos desta proposta são:

1. Realizar levantamento bibliográfico que tenha o objetivo de obter uma ampla visão dos principais desafios e técnicas utilizadas para extração de características de áudio e classificação de eventos sonoros no contexto de detecção de mosquitos;

2. Avaliar o impacto de diferentes técnicas de seleção de características de modo a definir um grupo de características que seja relevante para discriminação entre presença/ausência do *Aedes aegypti*;
3. Combinar características dos domínios do tempo, frequência e cepstral para oferecer uma boa discriminação entre presença e ausência do *Aedes aegypti* à luz de métricas de avaliação amplamente utilizadas;

2 Justificativa

Dentre 2008 a 2019, foram notificados no Brasil aproximadamente 11,6 milhões de casos de dengue, chikungunya e zika. Sendo que no mesmo período foram confirmados 7.043 óbitos ocasionados por essas doenças (BRASIL, 2020). Além disso, dentre janeiro de 2008 a agosto de 2021 foram gastos um total de R\$198.333.665,08 em serviços hospitalares em relação a dengue clássica e hemorrágica (OLIVEIRA, 2021).

Tendo em vista que o *Aedes Aegypti* é um inseto perigoso, o qual transmite 4 doenças, e seu método de reprodução pode ser evitado com a identificação e destruição de focos. Órgãos públicos combatem o mesmo enviando agentes de saúde aos locais para a realização de vistorias à procura desses criatórios de mosquitos, os quais necessitam manter visitas em ciclos. Gerando assim gastos, por exemplo, em termos de transporte e desgaste físico e o tempo necessário para localização e acesso a tais focos.

Portanto, como medidas de detecção de mosquitos por meio de sons estão cada vez mais sendo estudadas. Uma alternativa seria utilizar um dispositivo que capture o áudio ambiente a fim de detectar e notificar a presença do mosquito. Isso seria possível através da geração de um descritor que saiba diferenciar a existência do *Aedes Aegypti*. Um descritor compacto poderia ser embarcado em uma ampla gama de dispositivos, permitindo que um aplicativo para celular seja criado facilitando o uso do descritor de forma acessível. Por não depender totalmente da mão de obra humana os custos viriam somente em caso de raras manutenções.

3 Referencial Teórico

Esta seção busca fornecer uma breve revisão dos tópicos que são relevantes para este trabalho. Estando sub-dividida em abordagens sobre aquisição dos dados (Seção 3.1), a extração (Seção 3.2) e seleção (Seção 3.3) de características e classificação (Seção 3.4).

3.1 Base de dados

A obtenção de uma boa base de dados se torna essencial para o início de um trabalho. Essas bases podem conter diversos áudios de difentes formatos, taxas de amostragem, quantização e duração. Montar sua própria base pode ser cansativo e custoso. Visto isso, começaram a surgir bases públicas as quais são disponibilizadas por meio de algum projeto ou iniciativa de pesquisa, como por exemplo o projeto WINGBEATS (FANIOUDAKIS; GEISMAR; POTAMITIS, 2018) e a do Abuzz (MUKUNDARAJAN et al., 2017). Existe também bases privadas as quais seus dados pertencem apenas aquele proprietário ou a sua rede, que por sua vez, não há acesso para usá-las.

3.2 Extração de Características

A análise do áudio é dada através de um conjunto de características que possam ser extraídas dos frames para a representação do áudio. É nessa fase que a busca por características que melhor o representam é feita. Este trabalho girará em torno de três domínios: do tempo, do cepstral, e da frequência.

As características do domínio do tempo possuem ligação direta com a onda temporal que é formada pelo áudio (SERIZEL et al., 2018). Por exemplo, o *Tempogram* é uma representação de tempo o qual está ligada ao ritmo, a Figura 1 o representa matematicamente, onde t é o tempo de duração e l o tempo de atraso.

$$A(t, l) = \frac{\sum_{n \in \mathbb{Z}} \Delta(n) \Delta(n + l) \cdot W(n - t)}{2N + 1 - l}$$

Figura 1 – Fórmula *tempogram*

Já as características cepstrais fazem correspondência com a forma que nossa audição compreende os sons. Uma das características mais utilizadas é o Mel-Frequency Cepstral Coefficients (MFCCs) que tem relação direta com a forma como o ser humano identifica o som (VIRTANEN; PLUMBLEY; ELLIS, 2018). Sua fórmula é ilustrada na Figura 2.

$$MFCC(t, c) = \sqrt{\frac{2}{M_{mfcc}}} \sum_{m=1}^{M_{mfcc}} \log(|X|_m(t)) \cos\left(\frac{c(m - \frac{1}{2})}{M_{mfcc}}\right),$$

Figura 2 – Fórmula *MFCC*

E por fim, as características da frequência se concentram de forma direta nos componentes nos componentes de frequência do sinal do áudio. Tendo o Chroma STFT (Short-Time Fourier Transform - transformada de Fourier de curto tempo) como um poderoso atributo, e é visto como uma sucessiva avaliação das transformadas de *Fourier* (ELLIS, 2007). Segue sua fórmula na Figura 3.

$$STFT = F_g f[n, k] = \sum_{m=0}^{m-1} f[n - m] g[m] \epsilon_k[m]$$

Figura 3 – Fórmula *Chroma STFT*

3.3 Seleção de Características

Em alguns casos, utilizar de diversas características para descrever um áudio não é uma solução viável. Pois há chance de uma ou mais características acabarem causando redundância e até à geração de ruídos. Outro problema é em relação ao desempenho do descritor, já que um grande conjunto de características tende a gerar um vetor de alta dimensionalidade, sendo computacionalmente bastante custoso.

O objetivo desta etapa é filtrar o montante de características mantendo somente as que são relevantes para a discriminação dos mosquitos. Para isso que existem alguns algoritmos para a realização de tal tarefa. Um dos mais conhecidos é o Recursive Feature Elimination with Cross Validation (RFECV) (KOUL; MANVI, 2019) da biblioteca Scikit Learn. O RFE (CHEN et al., 2018) é um algoritmo que classifica as características por

importância, sendo este definido por um estimador como por exemplo o Random Forest. Enquanto o RFE faz a eliminação das características com menor relevância baseado no Random Forest, o RFECV utiliza o desempenho desses recursos selecionados no conjunto de dados de validação com a missão de decidir a importância dos mesmos.

3.4 Classificação

Nesta etapa é empregada uma abordagem supervisionada, a qual um modelo matemático é selecionado com a missão de mapear o vetor gerado após a extração ou seleção de características. O mesmo utiliza geralmente 80% dessas amostras para ser o conjunto de treinamento. Durante o treinamento os parâmetros do modelo são estimados sendo submetido a um conjunto de teste com os 20% restantes das amostras as quais são desconhecidas por parte dele.

Um dos classificadores mais conhecidos é o *Random Forest* (RF) (BREIMAN, 2001) o qual gera várias árvores de decisão tendo em cada uma delas um sub-conjunto de indicadores que foram escolhidos de maneira aleatória de forma que a mais votada é escolhida como modelo de classificação (ESMAIL; AHMED; ELTAYEB, 2019).

Em seguida a capacidade de extrapolação do modelo é medido por métricas de avaliação, por exemplo, a acurácia (BARATLOO et al., 2015) que defini-se pela seguinte fórmula 1:

$$Acc = \frac{VP + VN}{VP + VN + FP + FN}, \quad (1)$$

onde VP , VN , FP , e FN representam Verdadeiro Positivo, Verdadeiro Negativo, Falso Positivo e Falso Negativo, respectivamente. Quanto mais o valor se aproxima a 1, melhor é o resultado da acurácia.

Outra métrica bastante conhecida é o kappa de Cohen (COHEN, 1960) a qual representa como os classificadores selecionados se saíram melhor que o classificador que simplesmente adivinha de forma aleatória conforme a frequência de cada uma das classes. Os valores de seu índice são categorizados como: ruim ($\kappa \leq 0.2$), razoável ($0.21 \leq \kappa \leq 0.4$), bom ($0.41 \leq \kappa \leq 0.6$), muito bom ($0.61 \leq \kappa \leq 0.8$), e excelente ($\kappa \geq 0.81$). Ele é definido como:

$$\kappa = \frac{p_o - p_e}{1 - p_e}, \quad (2)$$

onde p_o é a probabilidade empírica de concordância no rótulo atribuído a qualquer amostra (concordância observada), e p_e é a concordância esperada quando ambos os anotadores atribuem rótulos aleatoriamente (concordância esperada).

4 Trabalhos Relacionados

Nesta seção serão apresentados os trabalhos que têm alguma relação com este. A Tabela 1 apresenta um breve resumo sobre os mesmos.

No artigo de (SILVA et al., 2013) desenvolveram uma armadilha inteligente para capturar sinais produzidos por insetos, sendo esses moscas e mosquitos. Dentre os mosquitos, temos as seguintes espécies: *Aedes aegypti* (4.756 amostras), *Anopheles gambiae* (1.411 amostras), *Culex quinquefasciatus* (3.137 amostras) e *Culex tarsalis* (5.309 amostras). Após a coleta dos dados, eles realizaram o pré-processamento das gravações e extração das características. A avaliação foi feita considerando os seguintes cenários: combinação de diferentes características para um mesmo classificador, combinação de diferentes classificadores

(comitê) para o mesmo tipo de característica e combinação de diferentes características submetida à um comitê de classificadores (SVM, KNN, GMM e RF). As características extraídas foram: Coeficientes Cepstral de Frequência Mel (MFCCs, do inglês: *mel-frequency cepstral coefficients*), Coeficientes de Codificação Preditiva Linear (LPC, do inglês: *linear predictive coding coefficients*), Frequências Espectrais de Linha (LSF, do inglês: *Line Spectral Frequencies*), e características temporais energia, magnitude, *root mean square energy*, *zero-crossing rate*, etc) e espectrais (*spectral centroid*, *spectral flatness measures*, *flux*, etc). Os autores concluíram que a combinação de diferentes classificadores para um mesmo tipo de característica não foi eficaz. Porém, a combinação de todas as características contribuíram na melhoria do desempenho dos classificadores individualmente. Na classificação binária, com a combinação de 40 MFCCs com o classificador support-vector machine (SVM) os mesmos obtiveram uma acurácia de 97.82%. Já na combinação das características espectrais, cepstrais e LSF, quando submetido ao comitê de classificação, obteve uma acurácia de 98%.

No artigo de (FERNANDES; CORDEIRO; RECAMONDE-MENDOZA, 2021) utilizaram espectrogramas extraídos de áudios de batimento das asas de mosquitos como entrada para uma rede neural convolucional (CNN, do inglês: *convolutional neural networks*) com o intuito de classificar 23 espécies diferentes, incluindo o *Aedes aegypti*. A base utilizada foi a do Abuzz project (MUKUNDARAJAN et al., 2017), mas com pequenas alterações em relação a sua organização. Os áudios foram capturados por smartphones em diferentes circunstâncias. Em relação aos testes obtiveram na classificação binária uma acurácia de 97.65% o qual é um resultado muito promissor. Já na classificação multiclasse 78.12% foram alcançados.

No artigo de (FANIOUDAKIS; GEISMAR; POTAMITIS, 2018) inspecionaram o sinal e os atributos de batida de asas de mosquitos. Para a obtenção dos áudios capturaram e colocaram 200-300 mosquitos adultos de ambos os sexos de uma determinada espécie em gaiolas, sendo a gravação realizada no momento em que passam pelos sensores. São elas: *Aedes aegypti*, *Aedes albopictus*, *Anopheles arabiensis*, *Anopheles gambiae*, *Culex pipiens*, *Culex quinquefasciatus*. Feito isso conseguiram no total 279.566 amostras (dataset denominado de WINGBEATS), sendo organizados 80% para treino e 20% para teste. Eles utilizaram redes de aprendizado profundo, sendo que, obtiveram os melhores resultados vinham da utilização dos espectrogramas dos áudios. Dentre elas, a InceptionV3 e a MobileNet alcançaram 95% de acurácia na classificação, sendo a DenseNet121 a que mais se destacou com 96%.

No artigo de (MULCHANDANI et al., 2019) utilizaram da mesma base que (FANIOUDAKIS; GEISMAR; POTAMITIS, 2018) a WINGBEATS. Treinaram várias CNNs com os espectrogramas obtidos dos respectivos áudios. Dentre elas, a que mais se destacou foi a Multi-Layer CNN, uma arquitetura de CNN própria, obtendo 86% de acurácia. Vale a pena mencionar, que diferente de outras redes neurais que como entrada espectrogramas, foi treinado também o XGBoost, que utiliza os arquivos de áudio diretamente em vez de convertê-los, e o mesmo alcançou 85.8%.

No artigo de (JHAVERI et al., 2022) apresentam modelos de aprendizado profundo que foram treinados com mel-spectrograms extraídos das amostras de áudios contendo o som produzido pelo batimento das asas dos mosquitos. A base utilizada também foi a WINGBEATS já citada neste trabalho. A fim de balancear o dataset, os autores fizeram a combinação de áudios para formar um único áudio contínuo por classe e, em seguida, cortaram essa combinação em amostras aleatórias do sinal de áudio com dimensão 5000.

Após o respectivo aumento dos dados, os autores organizaram a base de dados em 80% para treino e 20% para teste. Dito isso adotaram duas abordagens de classificação pré-treinadas com pesos da ImageNet: MobileNet, modelo menos profundo e adequado para aplicações com poder computacional limitado e que demanda por predições rápidas; e a DenseNet-121, uma arquitetura mais profunda. Os resultados concluíram que a MobileNet atingiu uma acurácia de 96,69%, enquanto que o DenseNet-121 atingiu uma acurácia de 97,03%. No entanto, o MobileNet acabou gastando metade do tempo de treinamento em comparação a DenseNet-121 e o mesmo também realiza predições três vezes mais rápidas.

Tabela 1 – Comparação dos trabalhos relacionados elencados.

TRABALHO	ANO	BASES	REPRESENTAÇÃO DO SOM	OBJETIVO	ACURÁCIA
(SILVA et al., 2013)	2013	Própria	Áudio	Combinar diversas características a fim de melhorar o resultado.	98%.
(FERNANDES; CORDEIRO; RECAMONDE-MENDOZA, 2021)	2021	Abuzz project	Espectogramas	Testar diferente formas de classificação de áudio.	97.65%
(FANIOUDAKIS; GEISMAR; POTAMITIS, 2018)	2018	Wingbeats	Espectogramas.	Fornecer áudios com qualidade para discriminar as espécies de mosquitos.	96%
(MULCHANDANI et al., 2019)	2019	Wingbeats	Espectogramas Áudios	Testar diferente formas de entrada de dados em prol de melhores resultados.	86%
(JHAVERI et al., 2022)	2022	Wingbeats	Melspectogramas	Combinar áudios para balancear a base de dados visando melhor resultado.	97%

5 Esboço da Proposta

Nesta seção será feita uma breve descrição da proposta deste trabalho. A proposta visa através da metodologia de extração manual das características, desenvolver um descritor que possibilite a identificação do *Aedes aegypti* e que possa ser embacarcado em um dispositivo móvel sem sobrecarregá-lo. Tendo isso em mente é desejável que o descritor tenha uma baixa dimensionalidade com o intuito de obtermos alta performance utilizando um baixo custo computacional.

Diante disso, a seleção de características será de extrema importância para o trabalho. Tendo em vista que iremos testar diversas características de diferentes domínios como por exemplo, do cepstral o *Mel-Frequency Cepstral Coefficients* (MFCCs), da frequência o *Chroma CENS*, e do tempo o *Zero Crossing Rate* (ZCR), onde nos deparamos com 3 características, tendo a possibilidade de alguma destas estar prejudicando o descritor existindo de forma irrelevante.

Dito isso, somente as características necessárias irão compor o descritor para que o mesmo consiga ser implantado em um dispositivo simples que possua microfone e realize a captação e processamento do áudio indicando a presença do *Aedes aegypti* no local. Com o descritor embarcado, diversas são as vertentes do seu uso, tendo o objetivo principal de auxiliar no monitoramento ajudando no combate ao mosquito.

6 Metodologia e Cronograma

Nesta seção será mostrada a metodologia proposta para detectar a presença do *Aedes Aegypti* neste trabalho. A metodologia usada nesse projeto para a obtenção dos resultados consiste em: aquisição dos dados; pré-processamento; extração de características; seleção de características; e classificação de eventos sonoros. A Figura 4 apresenta o fluxograma da metodologia à ser utilizada.

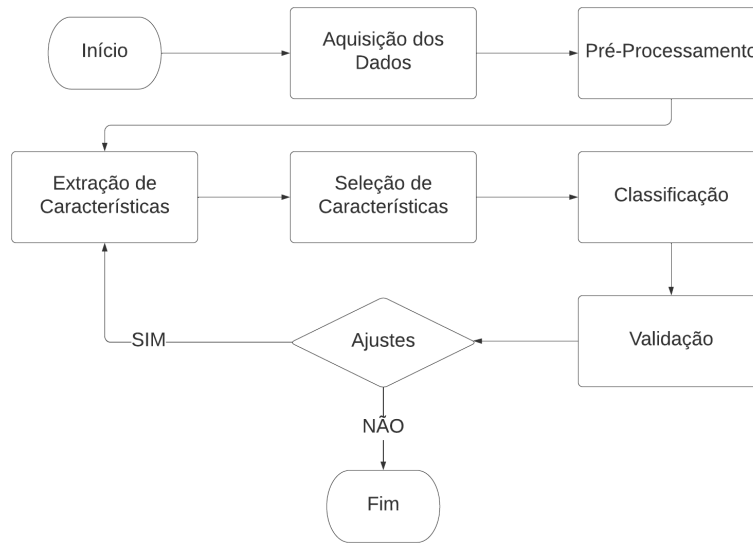


Figura 4 – Metodologia do projeto.

Aquisição dos dados: O desempenho dos classificadores é diretamente afetado pela qualidade e quantidade dos áudios coletados. Logo o processo de obtenção de amostras é desafiador, pois tem-se a existência de diversos fatores que podem interferir na coleta dos dados, como por exemplo, posicionamento do microfone, o espaço de propagação acústica, o tipo de dispositivo utilizado na captura, entre outros. Dito isso uma boa base de dados para sanar diversos desses fatores se torna essencial para a execução do trabalho. A base que será utilizada consiste em uma base pública disponibilizada pelo projeto Abuzz, a mesma utilizada por (FERNANDES; CORDEIRO; RECAMONDE-MENDOZA, 2021).

Pré-processamento: Tendo em vista que há a possibilidade de encontrarmos áudios com diferentes formatos, taxas de amostragem, quantização e duração. Nesta etapa é feita a uniformização do sinal de áudio com o intuito de garantir a qualidade e a homogeneidade, a distribuição das amostras para treino e teste, e se necessário, o aumento de amostras de classes com o objetivo de obter um melhor balanceamento na base de dados.

Extração de características: Nesta etapa busca-se obter de uma amostra de áudio características que possam representá-lo da melhor maneira possível para que o classificador possa distingui-lo dos demais.

Seleção de características: Algumas características podem ser redundantes e até mesmo ruídos devido a utilização de métodos não robustos. Logo essa etapa tem o objetivo de selecionar apenas as características que sejam relevantes para a discriminação entre as demais classes.

Classificação de eventos sonoros: Nesta etapa irá ser utilizada uma abordagem supervisionada, a qual um modelo matemático é selecionado para a realização de mapeamento do vetor de características, utilizando o subconjunto de amostras para seu treino. Em sequência o modelo treinado é submetido a um conjunto de teste com amostras desconhecidas. Mediante a isso a capacidade de extrapolação do modelo obtido é medido à luz de algumas métricas de desempenho.

Por fim, a Tabela 2 apresenta o cronograma planejado para execução do projeto.

Tabela 2 – Cronograma de atividades.

Atividades	Mês 1 - 2	Mês 3 - 6	Mês 7 - 8	Mês 9 - 10	Mês 11 - 12
Levantamento Bibliográfico	X	X			
Aquisição dos dados	X	X			
Pré-processamento		X			
Extração de características		X	X		
Seleção de características		X	X		
Classificação de eventos sonoros			X	X	
Redação da monografia			X	X	
Defesa da monografia					X

Referências

BARATLOO, A. et al. Part 1: simple definition and calculation of accuracy, sensitivity and specificity. *ARCHIVES OF ACADEMIC EMERGENCY MEDICINE (EMERGENCY)*, 2015. Citado na página 5.

BRASIL, M. da Saude do. *Óbito por arboviroses no Brasil, 2008 a 2019*. 2020. Disponível em: <<http://plataforma.saude.gov.br/anomalias-congenitas/boletim-epidemiologico-SVS-33-2020.pdf>>. Acesso em: 25 mar. 2020. Citado na página 3.

BREIMAN, L. Random forests. *Machine learning*, Springer, v. 45, n. 1, p. 5–32, 2001. Citado na página 5.

CHEN, Q. et al. Decision variants for the automatic determination of optimal feature subset in rf-rfe. *Genes*, Multidisciplinary Digital Publishing Institute, v. 9, n. 6, p. 301, 2018. Citado na página 4.

COHEN, J. A coefficient of agreement for nominal scales. *Educational and psychological measurement*, Sage Publications Sage CA: Thousand Oaks, CA, v. 20, n. 1, p. 37–46, 1960. Citado na página 5.

ELLIS, D. Chroma feature analysis and synthesis. *Resources of Laboratory for the Recognition and Organization of Speech and Audio-LabROSA*, v. 5, 2007. Citado na página 4.

ESMAIL, M. Y.; AHMED, D. H.; ELTAYEB, M. Classification system for heart sounds based on random forests. *Journal of Clinical Engineering*, LWW, v. 44, n. 2, p. 76–80, 2019. Citado na página 5.

FANIOUDAKIS, E.; GEISMAR, M.; POTAMITIS, I. Mosquito wingbeat analysis and classification using deep learning. In: IEEE. *2018 26th European Signal Processing Conference (EUSIPCO)*. [S.l.], 2018. p. 2410–2414. Citado 4 vezes nas páginas 2, 3, 6 e 7.

FERNANDES, M. S.; CORDEIRO, W.; RECAMONDE-MENDOZA, M. Detecting aedes aegypti mosquitoes through audio classification with convolutional neural networks. *Computers in Biology and Medicine*, Elsevier, v. 129, p. 104152, 2021. Citado 4 vezes nas páginas 2, 6, 7 e 8.

JHAVERI, A. et al. Deep learning-based mosquito species detection using wingbeat frequencies. In: *Intelligent Data Engineering and Analytics*. [S.l.]: Springer, 2022. p. 71–80. Citado 2 vezes nas páginas 6 e 7.

JOSHI, A.; MILLER, C. Review of machine learning techniques for mosquito control in urban environments. *Ecological Informatics*, Elsevier, v. 61, p. 101241, 2021. Citado na página 2.

KISKIN, I. et al. Humbug zooniverse: A crowd-sourced acoustic mosquito dataset. In: *ICASSP 2020 - 2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. [S.l.: s.n.], 2020. p. 916–920. Citado na página 2.

KOUL, N.; MANVI, S. S. A scheme for feature selection from gene expression data using recursive feature elimination with cross validation and unsupervised deep belief network classifier. In: IEEE. *2019 3rd International Conference on Computing and Communications Technologies (ICCT)*. [S.l.], 2019. p. 31–36. Citado na página 4.

MUKUNDARAJAN, H. et al. Using mobile phones as acoustic sensors for high-throughput mosquito surveillance. *eLife*, eLife Sciences Publications Limited, v. 6, p. e27854, 2017. Citado 2 vezes nas páginas 3 e 6.

MULCHANDANI, P. et al. Real-time mosquito species identification using deep learning techniques. *International Journal of Engineering and Advanced Technology*, p. 2249–8958, 2019. Citado 2 vezes nas páginas 6 e 7.

OLIVEIRA, A. B. S. de. O impacto da dengue na saUde pÚblica brasileira: Dinheiro pÚblico e vidas. In: *CONGRESSO NACIONAL DE DESENVOLVIMENTO DA SAÚDE (CONDESA)*. [S.l.: s.n.], 2021. p. 14–23. Citado na página 3.

SERIZEL, R. et al. Acoustic features for environmental sound analysis. In: *Computational analysis of sound scenes and events*. [S.l.]: Springer, 2018. p. 71–101. Citado na página 4.

SILVA, D. F. et al. Applying machine learning and audio analysis techniques to insect recognition in intelligent traps. In: IEEE. *2013 12th International Conference on Machine Learning and Applications*. [S.l.], 2013. v. 1, p. 99–104. Citado 2 vezes nas páginas 5 e 7.

VIRTANEN, T.; PLUMBLEY, M. D.; ELLIS, D. Introduction to sound scene and event analysis. In: *Computational analysis of sound scenes and events*. [S.l.]: Springer, 2018. p. 3–12. Citado na página 4.

Avaliação Final de TCC 01

ESTE DOCUMENTO DEVE SER PREENCHIDO PELO PROFESSOR AVALIADOR.

Este formulário será entregue junto com o pré-projeto impresso. Tal avaliação mais detalhada ajudará o aluno a evoluir seu trabalho futuro.

Professor, favor preencher antes da defesa apenas os nomes e a tabela de Avaliação Sobre o Documento.

Nome do Aluno: _____

Nome do Professor Avaliador: _____

Marque com um X a opção que melhor corresponde à sua avaliação.

Avaliação Sobre o Documento:

PARTE AVALIADA	RUIM	BOM	ÓTIMO
RESUMO			
INTRODUÇÃO			
OBJETIVOS			
REFERENCIAL TEÓRICO			
TRABALHOS RELACIONADOS			
PROPOSTA			
AVALIAÇÃO			
CRONOGRAMA			
ESCRITA EM GERAL			

Avaliação Sobre a Apresentação:

PARTE AVALIADA	RUIM	BOM	ÓTIMO
SEGURANÇA			
CLAREZA DE ARGUMENTAÇÃO			
TEMPO DE APRESENTAÇÃO			
SLIDES			

Nota :